Cluster-Orchestrierung

Bernhard Saumweber
bernhard.saumweber@qaware.de

Cluster Scheduling

Das Problem

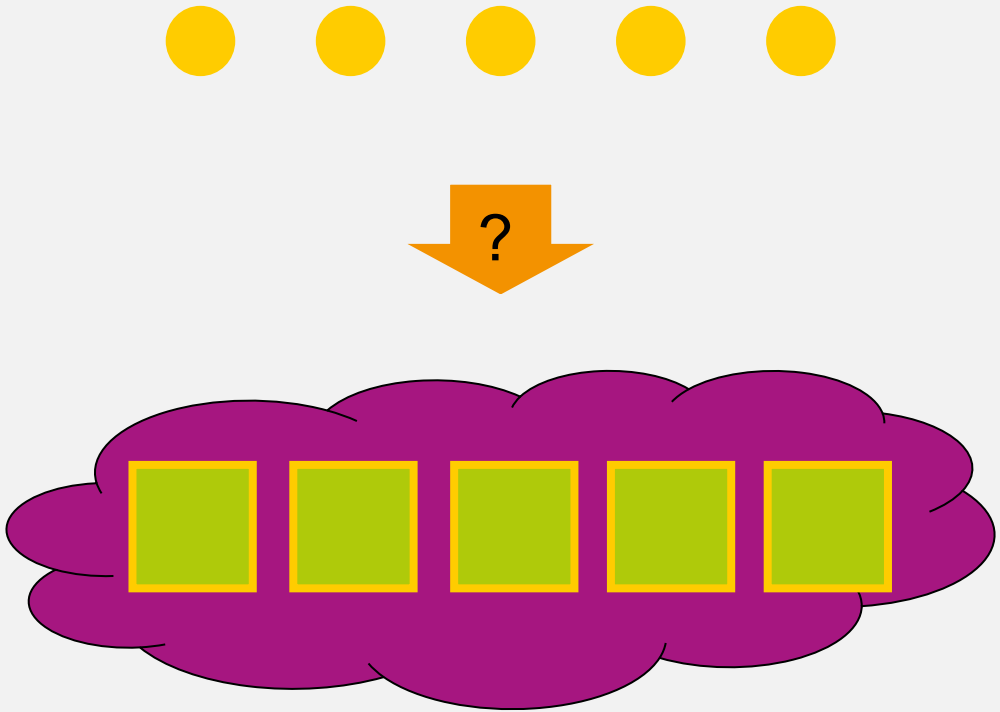

Rechenaufgaben

Rechen-Ressourcen (z.B. per IaaS)

Terminologie

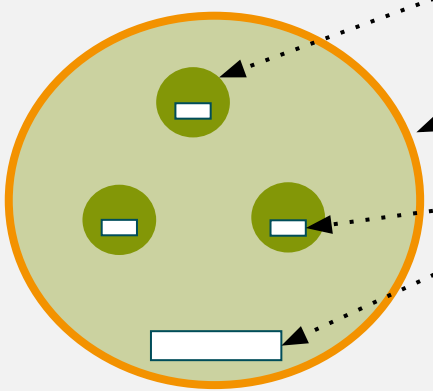

Task: Atomare Rechenaufgabe inklusive Ausführungsvorschrift.

Job: Menge an Tasks mit gemeinsamen Ausführungsziel. Die Menge an Tasks ist i.d.R. als DAG mit Tasks als Knoten und Ausführungs-abhängigkeiten als Kanten repräsentiert.

Properties: Ausführungsrelevante Eigenschaften der Tasks und Jobs, wie z.B.:

- Task: Ausführungsdauer, Priorität, Ressourcenverbrauch
- Job: Abhängigkeiten der Tasks, Ausführungszeitpunkt

Scheduler: Ausführung von Tasks auf den verfügbaren Resources unter Berücksichtigung der Properties und gegebener **Scheduling-Ziele** (z.B. Fairness, Durchsatz, Ressourcenauslastung). Ein Scheduler kann **präemptiv** sein, also die Ausführung von Tasks unterbrechen und neu aufsetzen können.

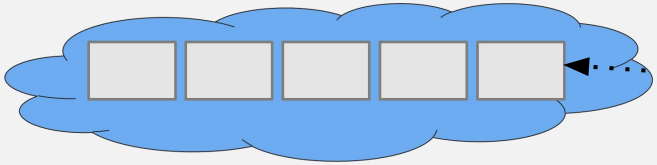

Resources: Cluster an Rechnern mit CPU-, RAM-, HDD-, Netzwerk-Ressourcen. Ein Rechner stellt seine Ressourcen temporär zur Ausführung eines oder mehrerer Tasks zur Verfügung (**Slot**). Die parallele Ausführung von Tasks ist isoliert zueinander.

Aufgaben eines Cluster-Schedulers:

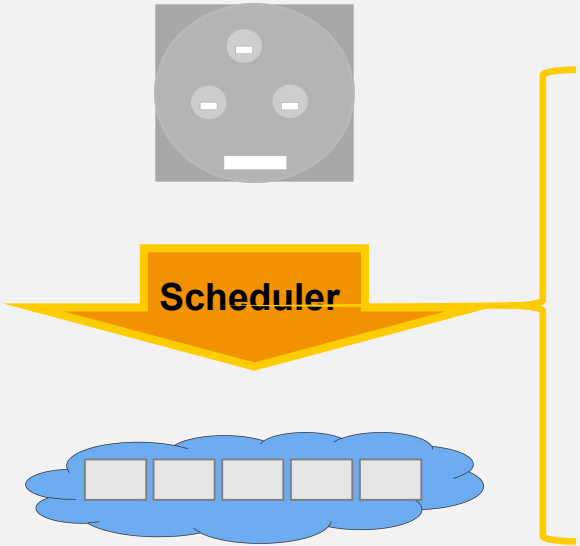

Cluster Awareness: Die aktuell verfügbaren Ressourcen im Cluster kennen (Knoten inkl. verfügbare CPUs, verfügbarer RAM und Festplattenspeicher sowie Netzwerkbandbreite). Dabei auch auf Elastizität reagieren.

Job Allocation: Zur Ausführung eines Services die passende Menge an Ressourcen für einen bestimmten Zeitraum bestimmen und allokieren.

Job Execution: Einen Service zuverlässig ausführen und dabei isolieren und überwachen.

Die einfachste Form des Scheduling: Statische Partitionierung

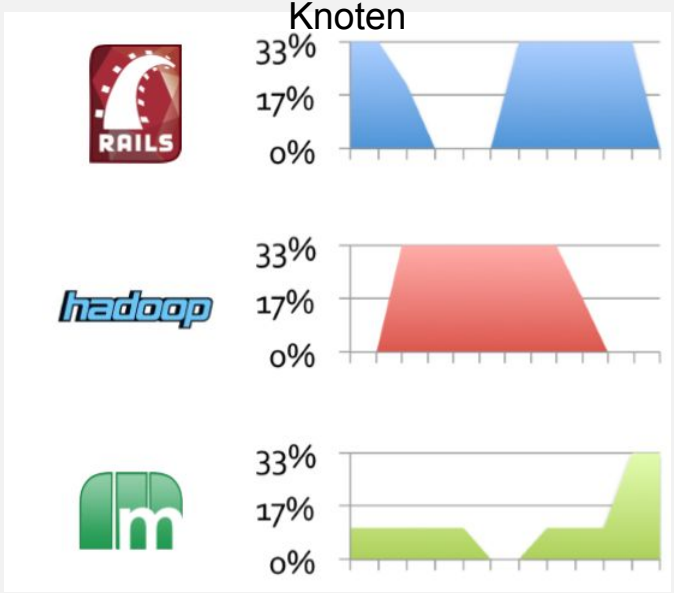

Vorteil:

- Einfach zu realisieren

Nachteile:

- Nicht flexibel bei geänderten Bedürfnissen
- Geringere Auslastung
  → hohe Opportunitätskosten

Bildquelle: Practical Considerations for Multi-Level Schedulers, Benjamin Hindman, 19th Workshop on Job Scheduling Strategies for Parallel Processing (JSSPP) 2015

Heterogenität im Scheduling

- In typischen Clustern ist die Workload an Jobs sehr heterogen.
- Charakteristische Unterschiede sind:
  - Ausführungsdauer: min, h, d, INF.
  - Ausführungszeit: sofort, später, zu einem Zeitpunkt.
  - Ausführungszweck: Datenverarbeitung, Request-Handling.
  - Ressourcenverbrauch: CPU-, RAM-, HDD-, NW-dominant.
  - Zustand: zustandsbehaftet, zustandslos.
- Zu unterscheiden sind mindestens:
  - **Batch-Jobs**: Ausführungszeit im Minuten- bis Stundenbereich. Eher niedrige Priorität und gut unterbrechbar. Müssen i.d.R. bis zu einem bestimmten Zeitpunkt abgeschlossen sein. Zustandsbehaftet.
  - **Service-Jobs**: Sollen auf unbestimmte Zeit unterbrechungsfrei laufen. Haben hohe Priorität und sollten nicht unterbrochen werden. Teilweise zustandslos.

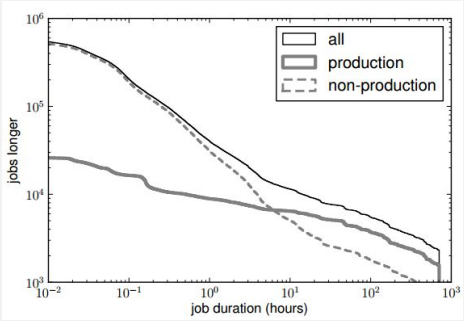

Ausführungsdauer

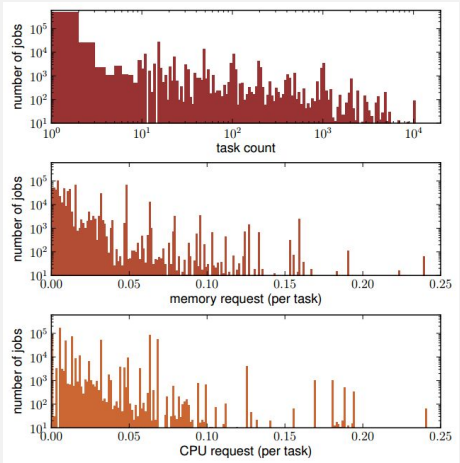

Ressourcenverbrauch

Heterogeneity and Dynamicity of Clouds at Scale: Google Trace Analysis, Charles Reiss et al., 2012

Bestehende Ressourcen einer Cloud können durch dynamische Partitionierung wesentlich effizienter genutzt werden.

QA|WARE

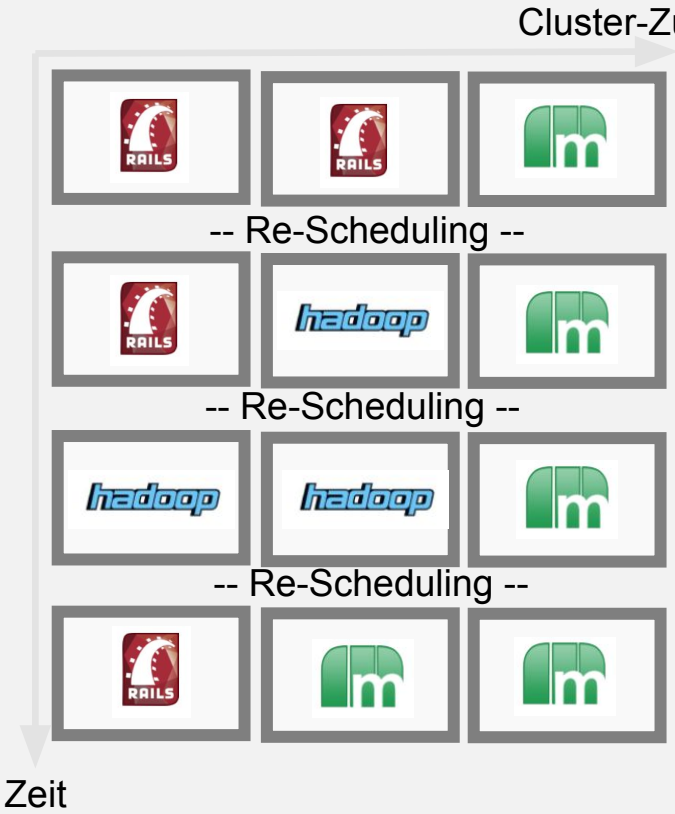

Statische Partitionierung **Dynamische Partitionierung**

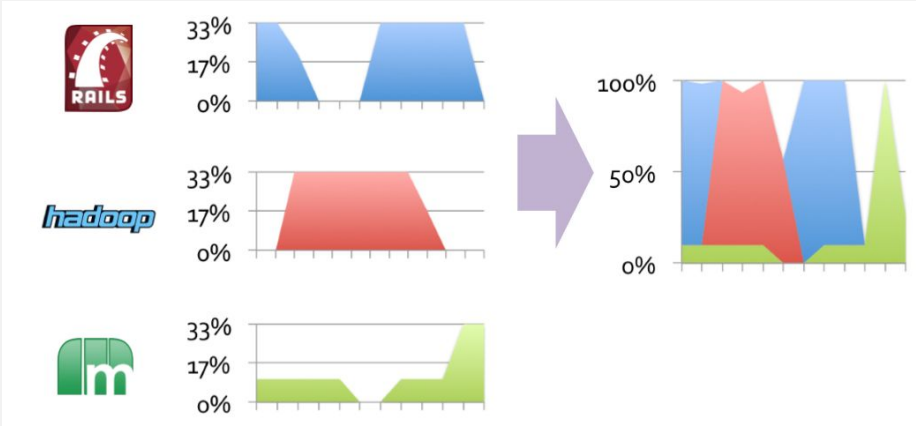

Vorteile der dynamischen Partitionierung:

- Höhere Auslastung der Ressourcen → weniger Ressourcen notwendig → geringere Betriebskosten
- Potenziell schnellere Ausführung einzelner Tasks, da Ressource opportun genutzt werden können.

Ein Cluster-Scheduler: Eingabe, Verarbeitung, Ausgabe.

Eingabe eines Cluster-Schedulers ist Wissen über die Jobs und Tasks (Properties) und über die Ressourcen:

- **Resource Awareness**: Welche Ressourcen stehen zur Verfügung und wie ist der entsprechende Bedarf des Tasks?
- **Data Awareness**: Wo sind die Daten, die ein Task benötigt?
- **QoS Awareness**: Welche Ausführungszeiten müssen garantiert werden?
- **Economy Awareness**: Welche Betriebskosten dürfen nicht überschritten werden?
- **Priority Awareness**: Wie ist die Priorität der Task zueinander?
- **Failure Awareness**: Wie hoch ist die Wahrscheinlichkeit eines Ausfalls? (z.B. da ein Rack oder eine Stromvers.)
- **Experience Awareness**: Wie hat sich ein Tasks in der Vergangenheit verhalten?

Ein Cluster-Scheduler: Eingabe, **Verarbeitung**, Ausgabe.

Verarbeitung im Cluster-Scheduler: **Scheduling-Algorithmen** entsprechend der jeweiligen **Scheduling-Ziele**, wie z.B.:

- **Fairness**: Kein Task sollte unverhältnismäßig lange warten müssen, während ein anderer bevorzugt wird.
- **Maximaler Durchsatz**: So viele Tasks pro Zeiteinheit wie möglich.
- **Minimale Wartezeit**: Möglichst geringe Zeit von der Übermittlung bis zur Ausführung eines Tasks.
- **Ressourcen-Auslastung**: Möglichst hohe Auslastung der verfügbaren Ressourcen.
- **Zuverlässigkeit**: Ein Task wird garantiert ausgeführt.
- **Geringe End-to-End Ausführungszeit** (z.B. durch Daten-Lokalität und geringe Kommunikationskosten, syn. Makespan)

Ein Cluster-Scheduler: Eingabe, Verarbeitung, **Ausgabe.**

<u>Ausgabe</u> eines Cluster-Schedulers:
Placement Decision als

- **Slot-Reservierungen**
- **Slot-Stornierungen** (im Fehlerfall, Optimierungsfall, Constraint-Verletzung)

Hauptziel ist es oft, die Ressourcen-Auslastung zu optimieren. Das spart Opportunitätskosten.

Scheduling ist eine Optimierungsaufgabe…

… und ist NP-vollständig.
Die Optimierungsaufgabe lässt sich auf das Traveling Salesman Problem zurückführen.

Das bedeutet:

- Es ist kein Algorithmus bekannt, der eine optimale Lösung garantiert in Polynomialzeit erzeugt.
- Algorithmus muss für tausende Jobs und tausende Ressourcen skalieren. Optimale Algorithmen, die den Lösungsraum komplett durchsuchen sind nicht praktikabel, da deren Entscheidungszeit zu lange ist für große Eingabemengen (|Jobs| x |Ressourcen|).
- Praktikable Scheduling-Algorithmen sind somit Algorithmen zur näherungsweisen Lösung des Optimierungsproblems (Heuristiken, Meta-Heuristiken).

Darüber hinaus kommen Job-Anfragen kontinuierlich an, so dass selbst bei optimalem Algorithmus der Re-Organisationsaufwand pro Job unverhältnismäßig hoch werden kann.

Einfache Scheduling-Algorithmen

QA|WARE

– Optimieren das Scheduling von Tasks oft in genau einer Dimension (z.B. CPU-Auslastung) bzw. wenigen Dimensionen (CPU-Auslastung und RAM).

– Populäre Algorithmen:
  - Binpack (Fit First)
  - Spread (Round Robin)

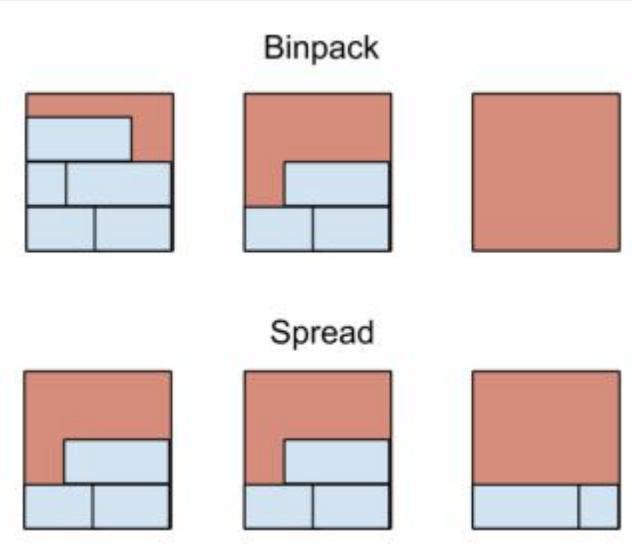

http://www.binpacking.4fan.cz
http://container-solutions.com/using-binpack-with-docker-swarm

Kubernetes engineers when they don't have a kitchen towel

QA|WARE

Das Big Picture: Wir sind nun auf Applikationsebene.

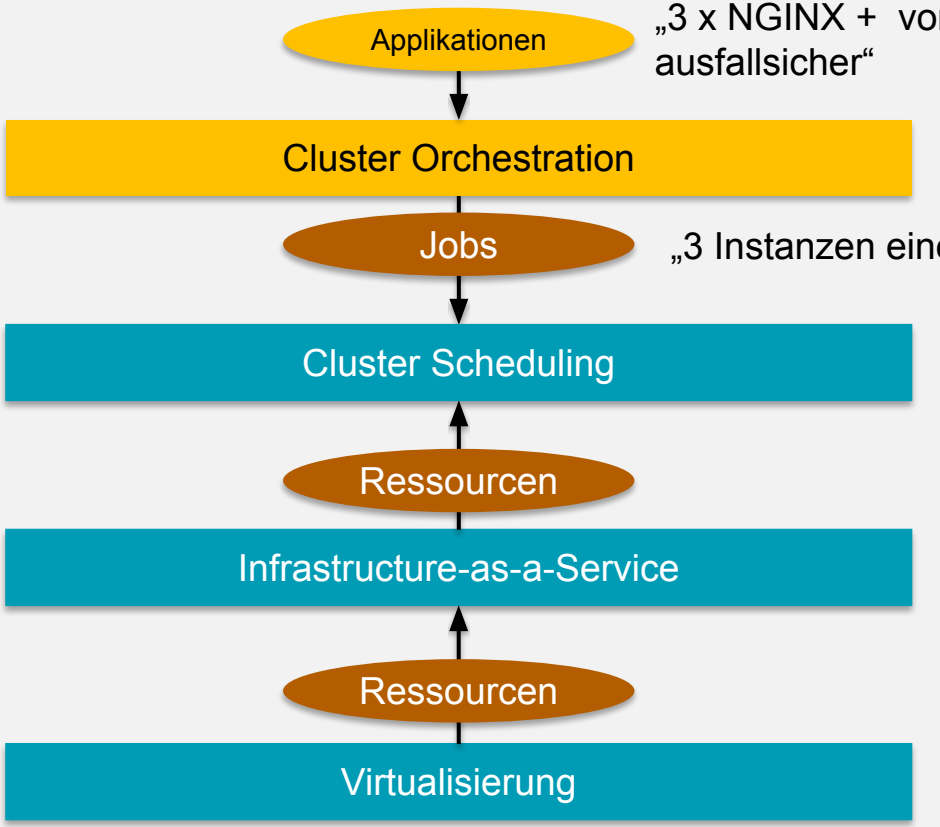

Cluster-Orchestrierung: Beispiel

Frontend Service

Backend Service

Database

Anwendungen

Betriebssystem

Dependencies

Interessiert Dev

Cluster Orchestrator

Deployment

Networking (Loadbalancing, Service Discovery, …)

Scaling

„Insight“ (Logging, Analytics, Rescheduling, Failure Recovery, …)

Interessiert (Dev)Ops

Cluster-Orchestrierung

Ziel: Eine Anwendung, die in mehrere Betriebskomponenten (Container) aufgeteilt ist, auf mehreren Knoten laufen lassen.

Führt Abstraktionen zur Ausführung von Anwendungen mit ihren Services in einem großen Cluster ein.

Orchestrierung ist keine statische, einmalige Aktivität wie die Provisionierung, sondern eine dynamische, kontinuierliche Aktivität.

Orchestrierung hat den Anspruch, alle Standard-Betriebsprozeduren einer Anwendung zu automatisieren.

Blaupause der Anwendung, die den gewünschten Betriebszustand der Anwendung beschreibt: Betriebskomponenten (Container), deren Betriebsanforderungen sowie die angebotenen und benötigten Schnittstellen.

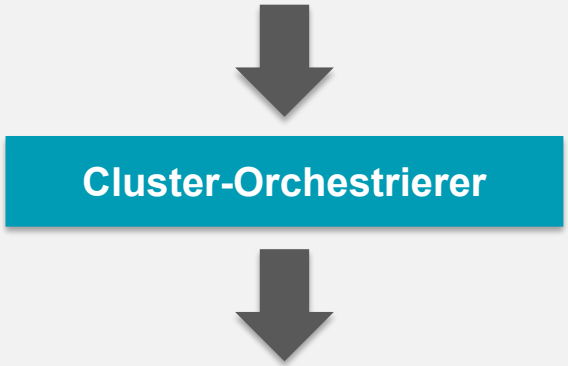

Steuerungsaktivitäten im Cluster:

- Start von Containern auf Knoten (→ Scheduler)
- Verknüpfung von Containern
- …

Ein Cluster-Orchestrierer bietet eine Schnittstelle zwischen Betrieb und Entwicklung für ein Cluster an.

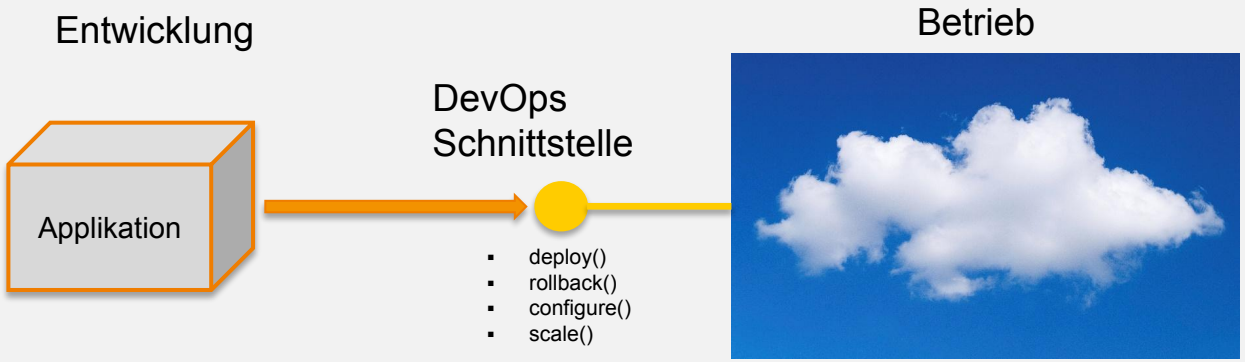

Blaupause einer Anwendung (vereinfacht)

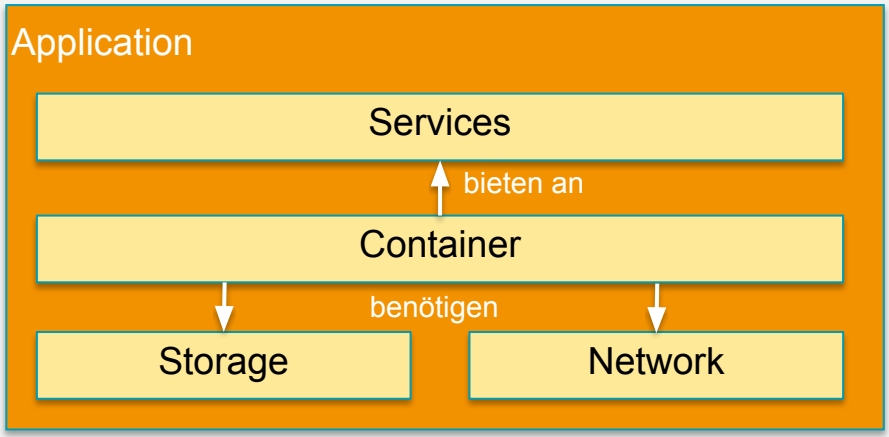

Metamodell

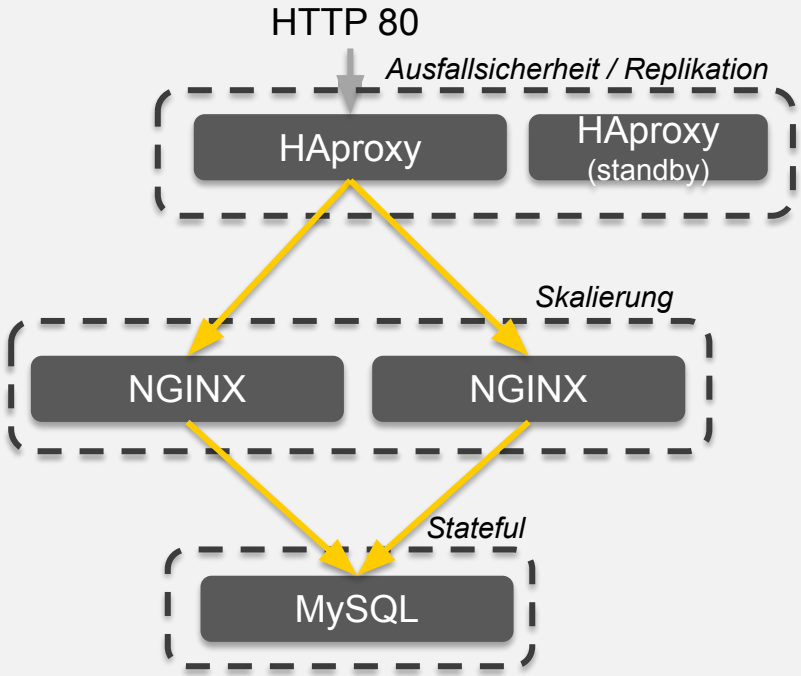

Modell

Analogie 1: Lego Star Wars

QA|WARE

Services (angeboten)

Container

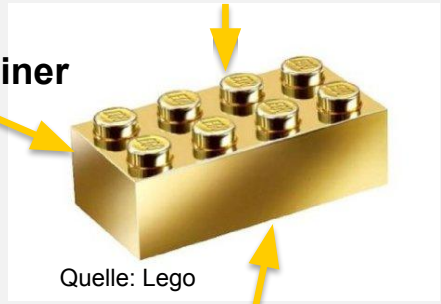

Quelle: Lego

Services (benötigt)

Cluster-Orchestrierer

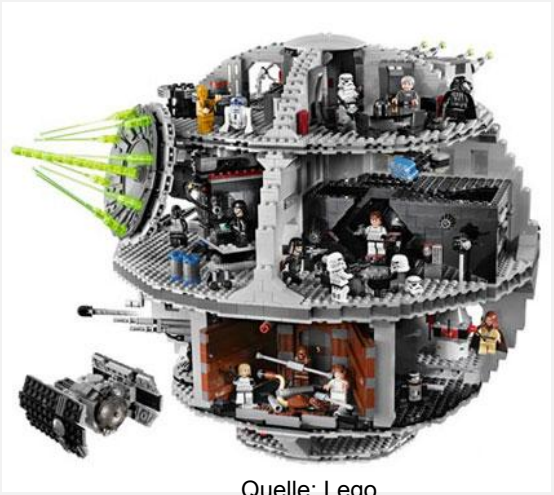

Quelle: Lego

Cluster-Scheduler

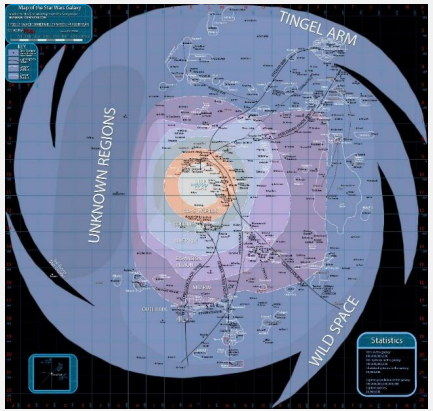

Quelle: wikipedia.de

Blaupause

Analogie 1: Applikationsserver

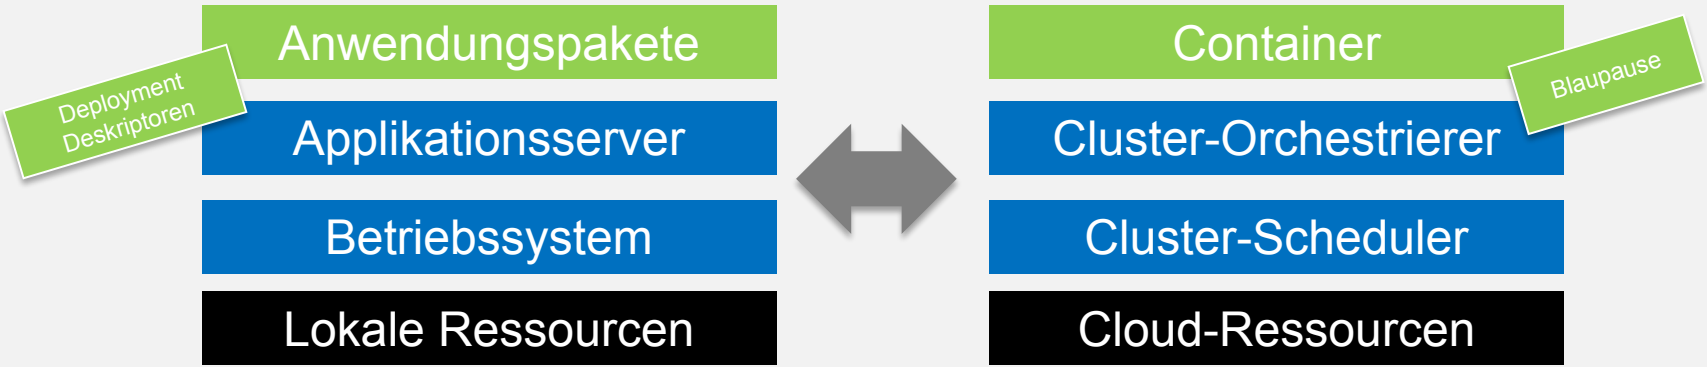

Analogie 2: Betriebssystem

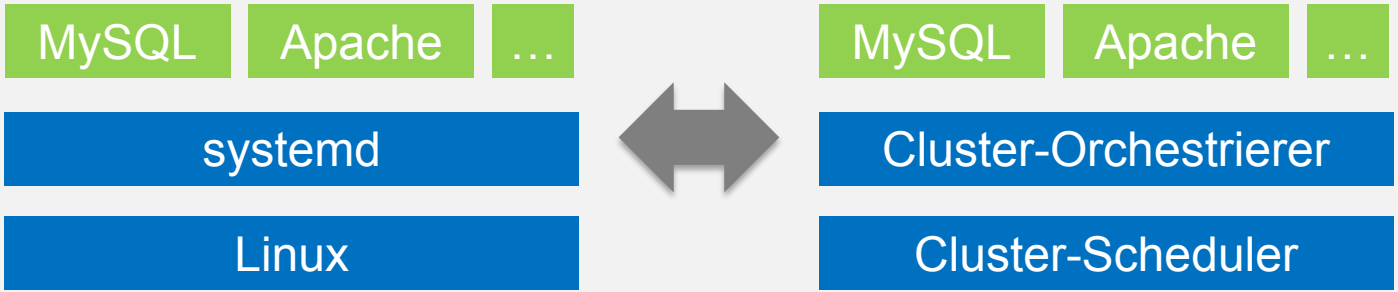

Ein Cluster-Orchestrierer automatisiert vielerlei Betriebsaufgaben für Anwendung auf einem Cluster (1 / 2):

- Scheduling von Containern mit applikationsspezifischen Constraints (z.B. Deployment- und Start-Reihenfolgen, Gruppierung, …)
- Aufbau von notwendigen Netzwerk-Verbindungen zwischen Containern.
- Bereitstellung von persistenten Speichern für zustandsbehaftete Container.
- (Auto-)Skalierung von Containern.
- Re-Scheduling von Containern im Fehlerfall (Auto-Healing) oder zur Performance-Optimierung.
- Container-Logistik: Verwaltung und Bereitstellung von Containern.

Ein Cluster-Orchestrierer automatisiert vielerlei Betriebsaufgaben für Anwendung auf einem Cluster (2 / 2):

- Package-Management: Verwaltung und Bereitstellung von Applikationen.
- Bereitstellung von Administrationsschnittstellen (Remote-API, Kommandozeile).
- Management von Services: Service Discovery, Naming, Load Balancing.
- Automatismen für Rollout-Workflows wie z.B. Canary Rollout.
- Monitoring und Diagnose von Containern und Services.

1-Level- vs. 2-Level-Orchestrierung

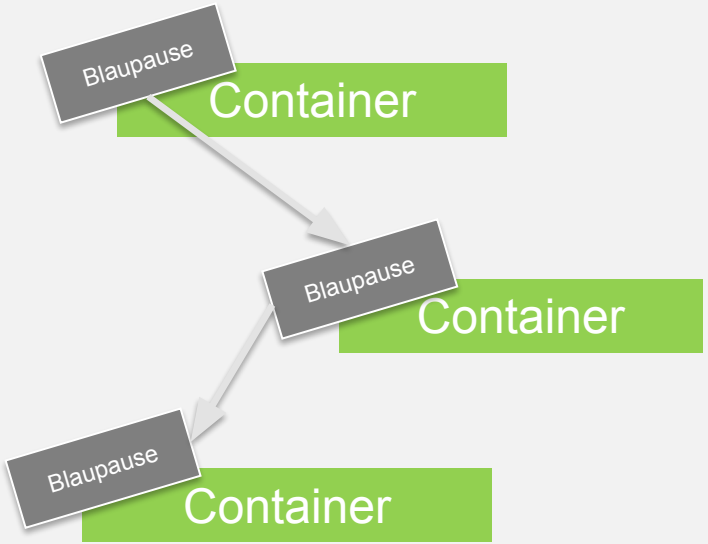

1-Level-Orchestrierung
(Container-Graph)

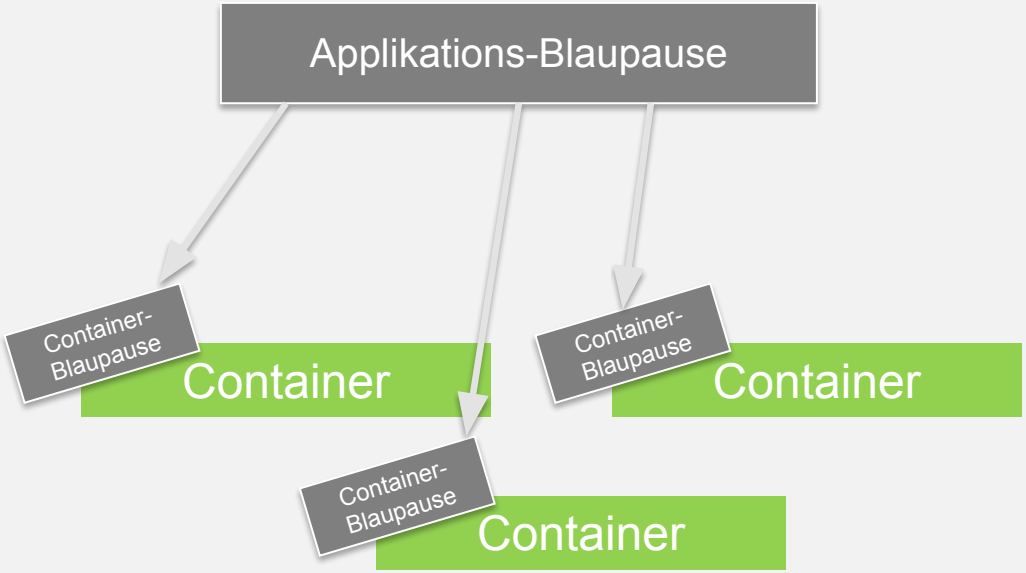

2-Level-Orchestrierung
(Container-Repository mit zentraler Bauanleitung)

1-Level- vs. 2-Level-Orchestrierung

Plain Docker

```
FROM ubuntu
ENTRYPOINT nginx
EXPOSE 80

docker run -d --link
nginx:nginx
```

1-Level-Orchestrierung
(Container-Graph)

https://docs.docker.com/compose/compose-file

Docker Compose

```
weba:
  image: qaware/nginx
  expose:
     - 80

webb:
  image: qaware/nginx
  expose:
     - 80

haproxy:
   image: qaware/haproxy
   links:
      - weba
      - webb
   ports:
      - “80:80“
   expose:
      - 80
```

```
FROM ubuntu
ENTRYPOINT nginx
EXPOSE 80
```

```
FROM ubuntu
ENTRYPOINT haproxy
EXPOSE 80
```

2-Level-Orchestrierung
(Container-Repository mit zentraler Bauanleitung)

Kubernetes

kubernetes by Google

Manage a cluster of Linux containers as a single system to accelerate Dev and simplify Ops.

http://kubernetes.io

Kubernetes

- Cluster-Orchestrierer auf Basis von Containern, der eine Reihe an Kern-Abstraktionen für den Betrieb von Anwendungen in einem großen Cluster einführt. Die Blaupause wird über YAML-Dateien definiert.
- Open-Source-Projekt, das von Google initiiert wurde. Google will damit die jahrelange Erfahrung im Betrieb großer Cluster der Öffentlichkeit zugänglich machen und damit auch Synergien mit dem eigenen Cloud-Geschäft heben.
- Seit Juli 2015 in der Version 1.0 verfügbar und damit produktionsreif. Skaliert aktuell nachweislich auf 1000 Nodes großen Clustern.
- Bei vielen Firmen im Einsatz wie z.B. Google im Rahmen der Google Container Engine, Wikipedia, ebay. Beiträge an der Codebasis aus vielen Firmen neben Google – u.A. Mesosphere, Microsoft, Pivotal, RedHat.
- Setzt den Standard im Bereich Cluster-Orchestrierung. Dafür wurde auch eigens die Cloud Native Computing Foundation gegründet (https://cncf.io).

Architektur von Kubernetes

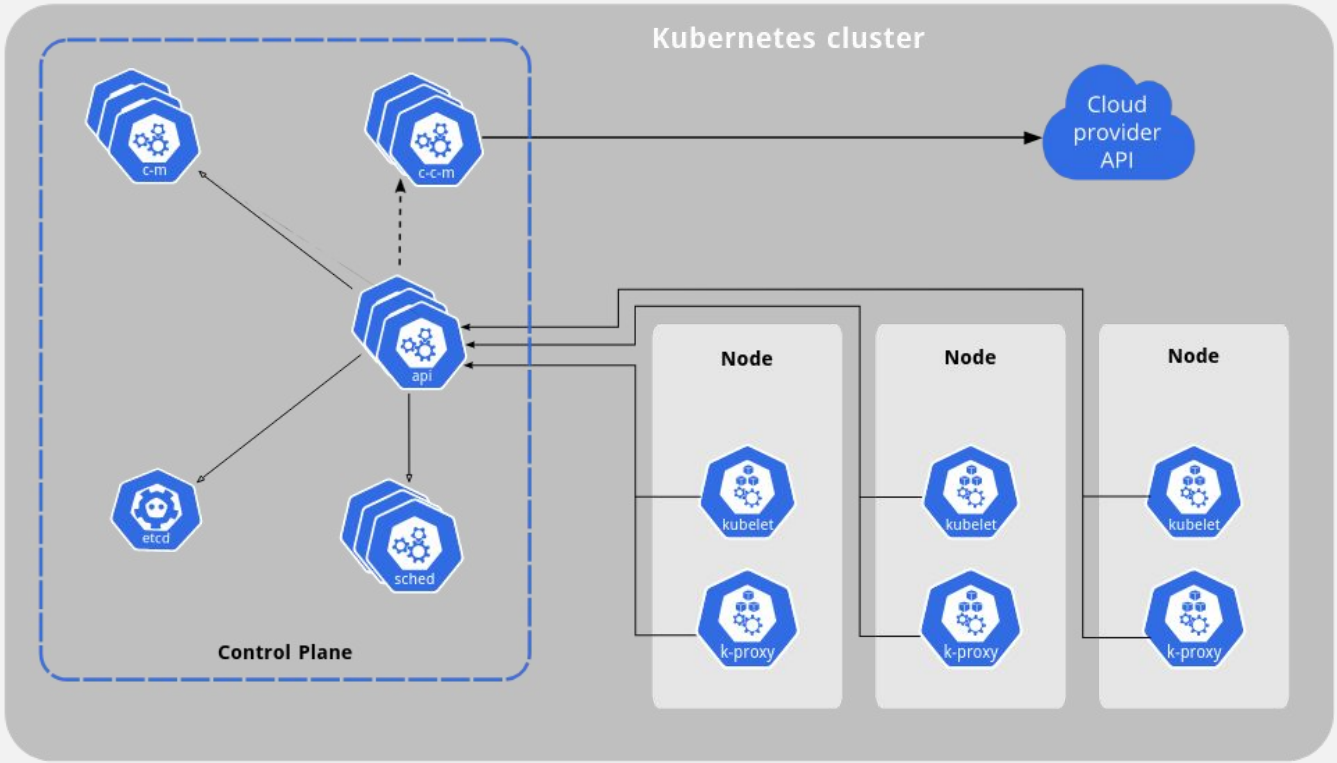

API server

Cloud controller manager *(optional)*

Controller manager

etcd (persistence store)

kubelet

kube-proxy

Scheduler

Control plane

Node

Pods & Deployments

Wichtige Kubernetes-Konzepte

Der Grundbaustein ist eure **Anwendung**.

App

Wichtige Kubernetes-Konzepte

Der Grundbaustein ist eure **Anwendung**.

Die **Anwendung** steckt in einem **Container** (siehe Vorlesung “Virtualisierung”). **Container** öffnen **Ports** nach außen.

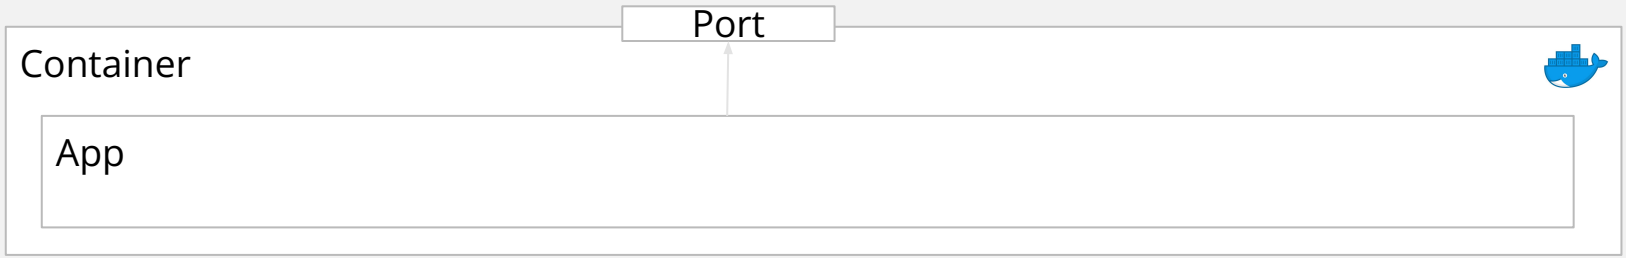

Wichtige Kubernetes-Konzepte

QA|WARE

Der Grundbaustein ist eure **Anwendung**.

Die **Anwendung** steckt in einem **Container** (siehe Vorlesung “Virtualisierung”). **Container** öffnen **Ports** nach außen.

Container werden in Kubernetes zu **Pods** zusammengefasst. **Pods** haben nach außen hin eine I**P-Adresse**.

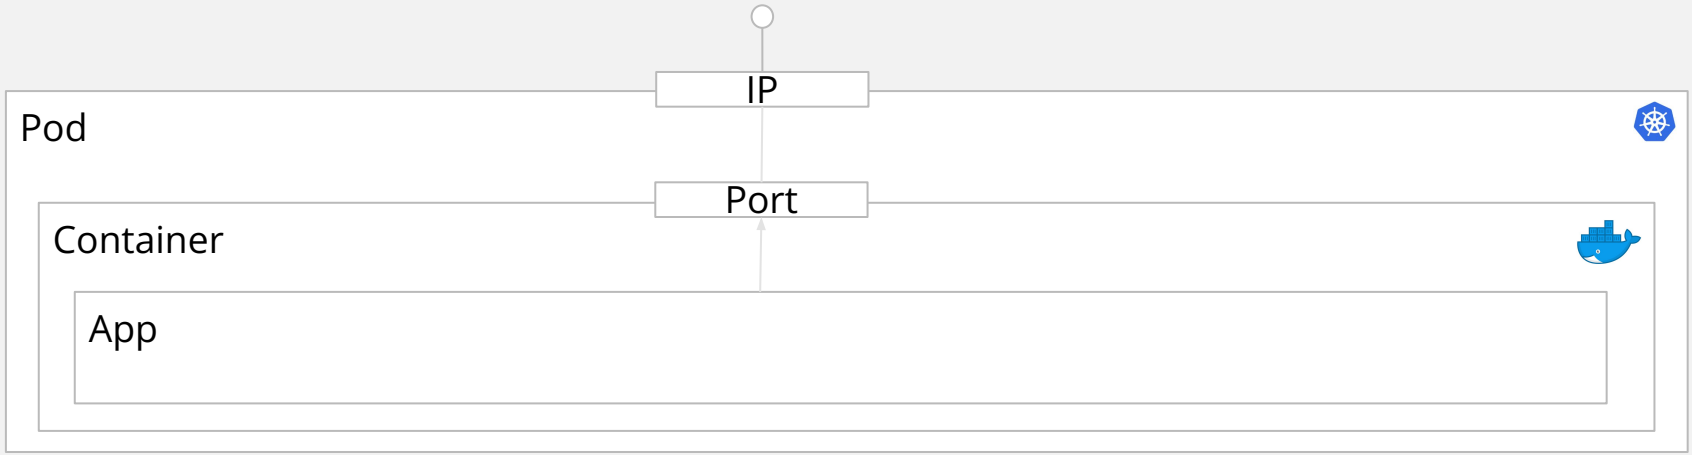

Wichtige Kubernetes-Konzepte

In einem **Pod** können auch mehrere **Container** laufen.

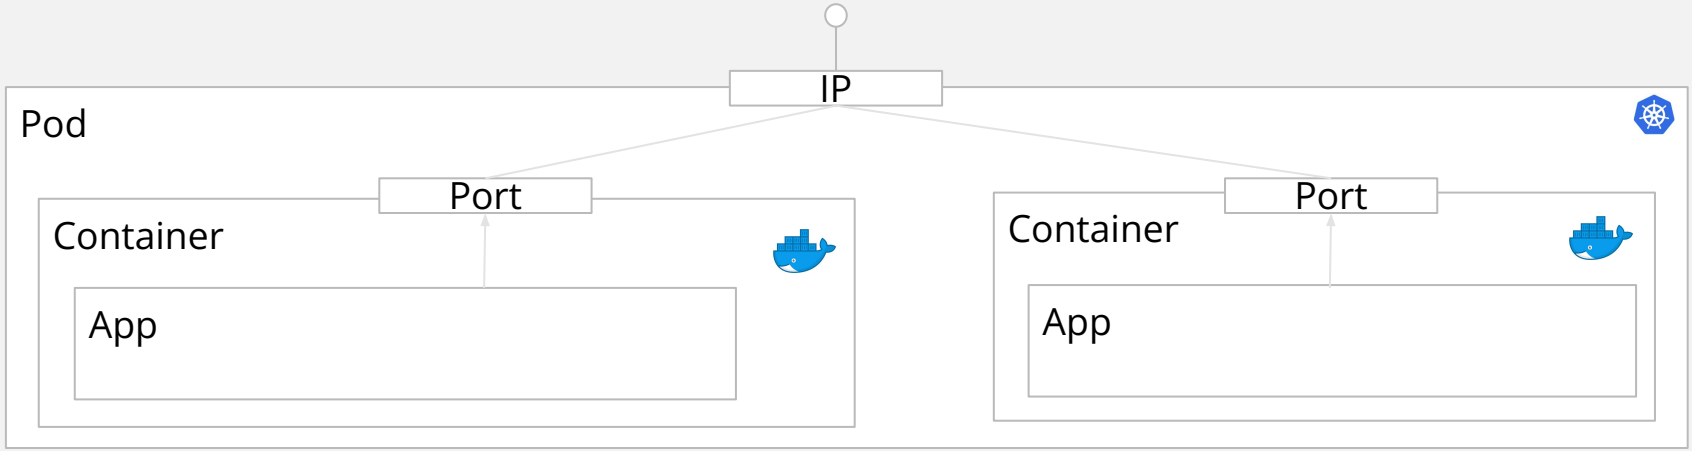

Wichtige Kubernetes-Konzepte

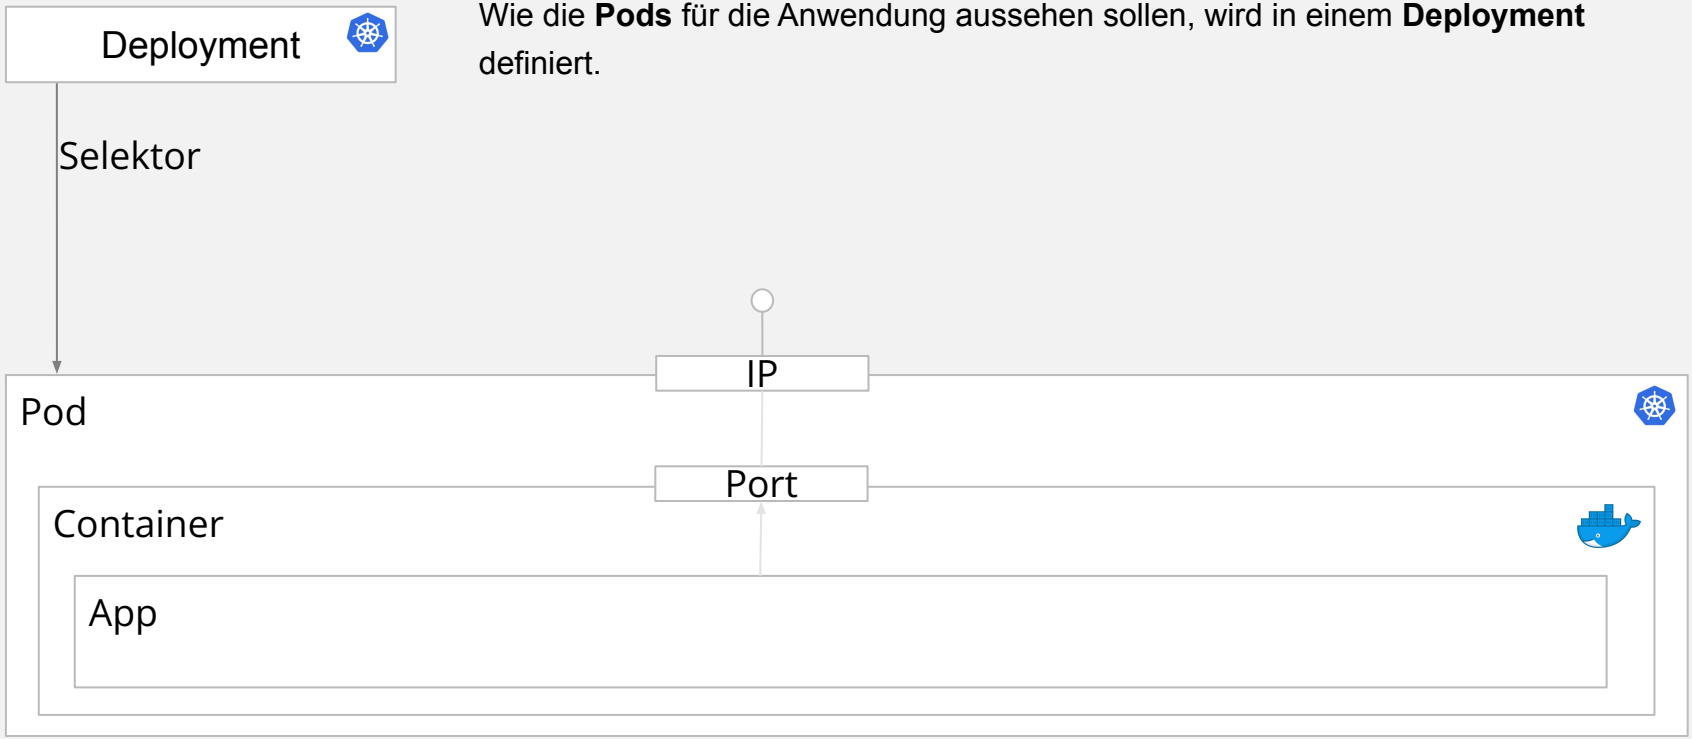

Wie die **Pods** für die Anwendung aussehen sollen, wird in einem **Deployment** definiert.

Wichtige Kubernetes-Konzepte

QA|WARE

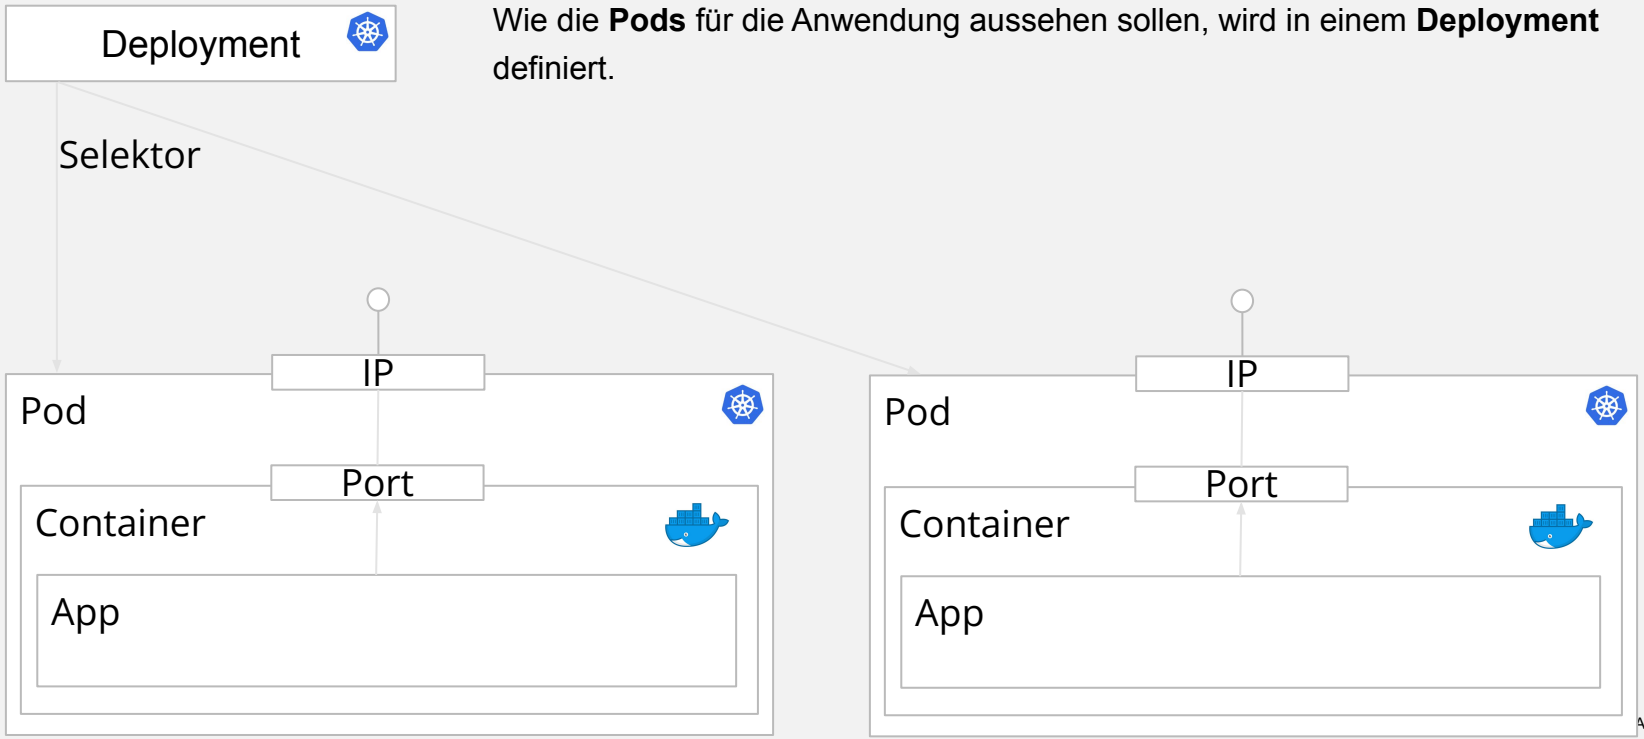

Wie die **Pods** für die Anwendung aussehen sollen, wird in einem **Deployment** definiert.

Deployment: Definition


```yaml
apiVersion: apps/v1
kind: Deployment
metadata:
  name: hello-service
spec:
  replicas: 3
  template:
    metadata:
      labels:
        app: helloservice
    spec:
      containers:
      - name: hello-service
        image: "hitchhikersguide/zwitscher-service:1.0.1"
        ports:
        - containerPort: 8000
        env:
        - name:
          value: zwitscher-consul
```

Big Picture: Hello-Service

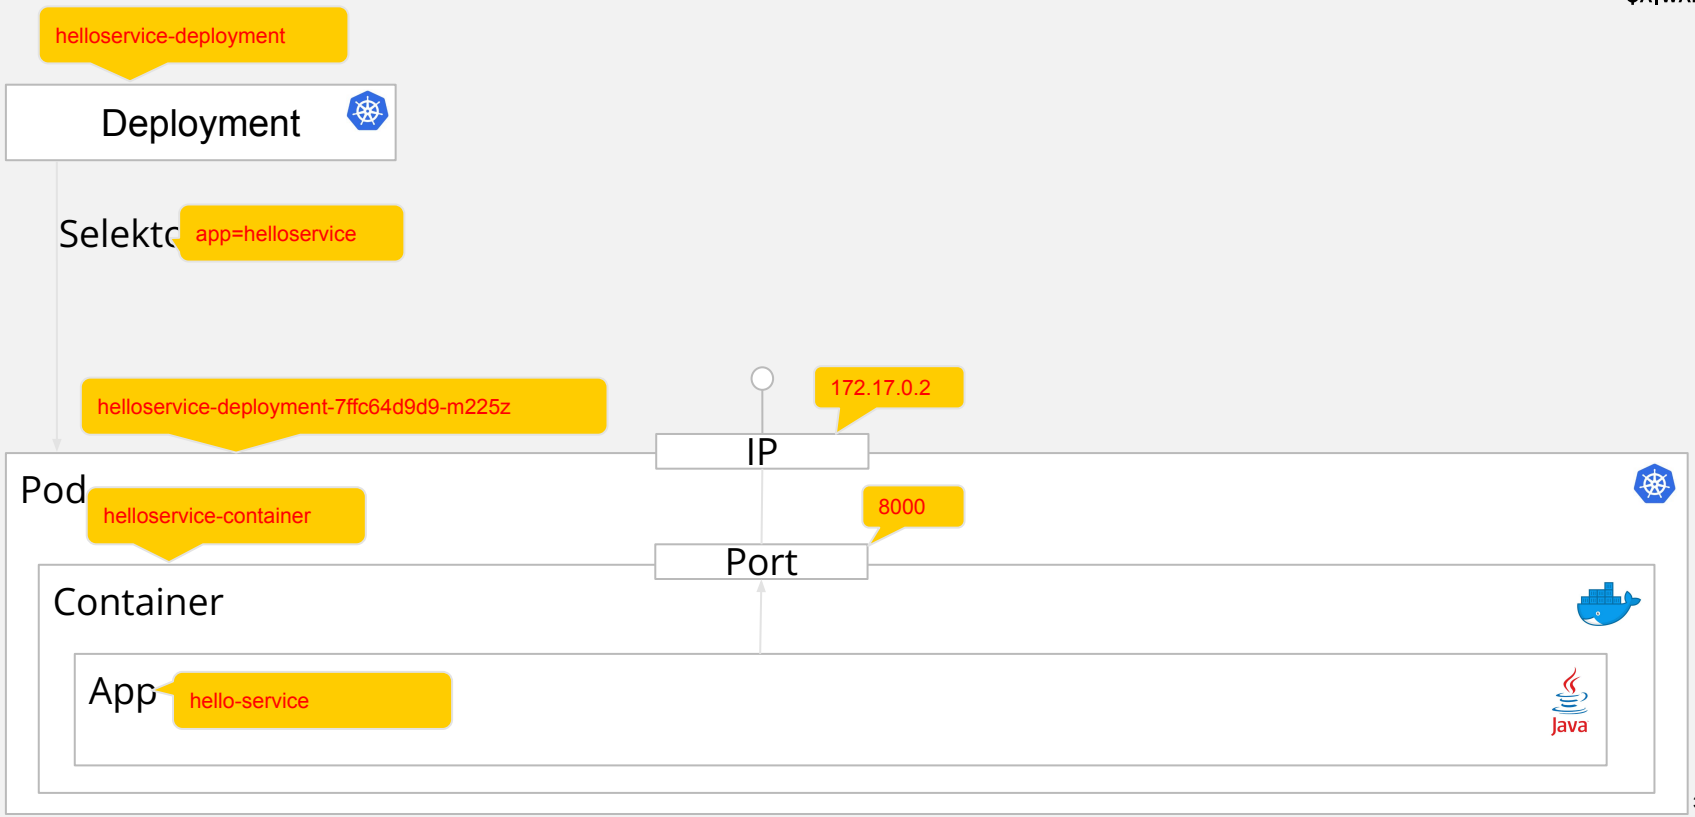

Probes & Resources

Resource Constraints


```yaml
resources:
  # Define resources to help K8S scheduler

  # CPU is specified in units of cores
  # Memory is specified in units of bytes

  # required resources for a Pod to be started
  requests:
    memory: "128M"
    cpu: "0.25"

  # the Pod will be restarted if limits are exceeded
  limits:
    memory: "192M"
    cpu: "0.5"
```

Liveness und Readiness Probes


```yaml
# container will receive requests if probe succeeds
readinessProbe:
  httpGet:
    path: /admin/info
    port: 8080
  initialDelaySeconds: 30
  timeoutSeconds: 5

# container will be killed if probe fails
livenessProbe:
  httpGet:
    path: /admin/health
    port: 8080
  initialDelaySeconds: 90
  timeoutSeconds: 10
```

Services

Wichtige Kubernetes Konzepte

QA|WARE

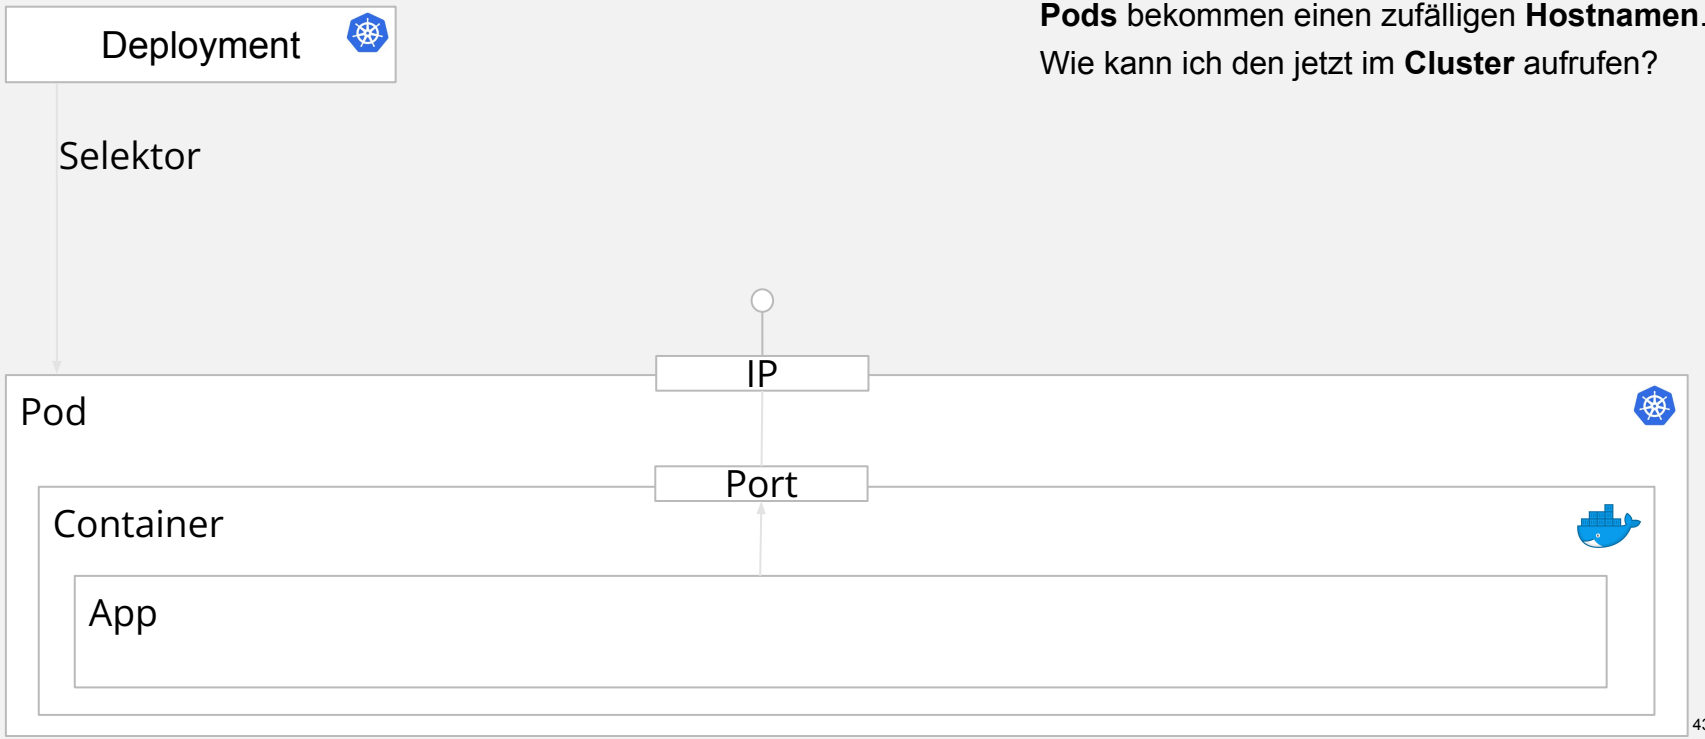

Pods bekommen einen zufälligen **Hostnamen**.
Wie kann ich den jetzt im **Cluster** aufrufen?

Wichtige Kubernetes Konzepte

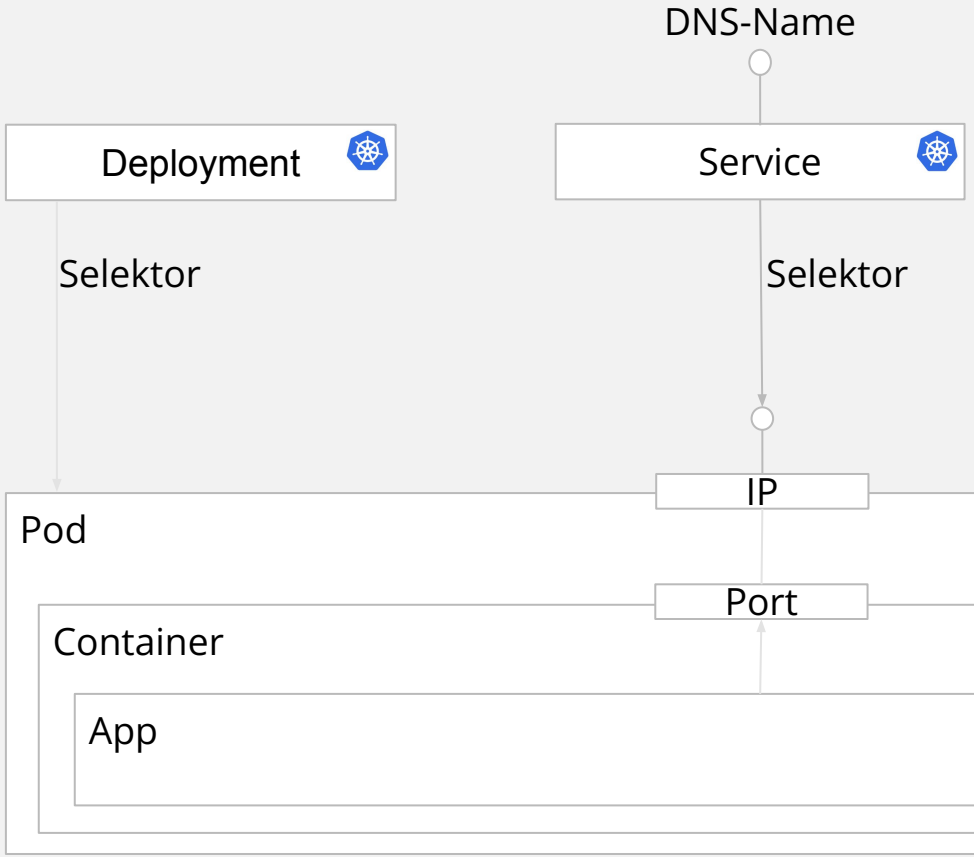

Pods bekommen einen zufälligen **Hostnamen**. Wie kann ich den jetzt im **Cluster** aufrufen?

Ein **Service** vergibt einen **DNS-Namen** für ein Set von **Pods**.

Service: Definition


```yaml
apiVersion: v1
kind: Service
metadata:
  name: hello-service
  labels:
    app: helloservice
spec:
  # use NodePort here to be able to access the port on each node
  # use LoadBalancer for external load-balanced IP if supported
  type: NodePort
  ports:
  - port: 8080
  selector:
    app: helloservice
```

Big Picture: Hello-Service

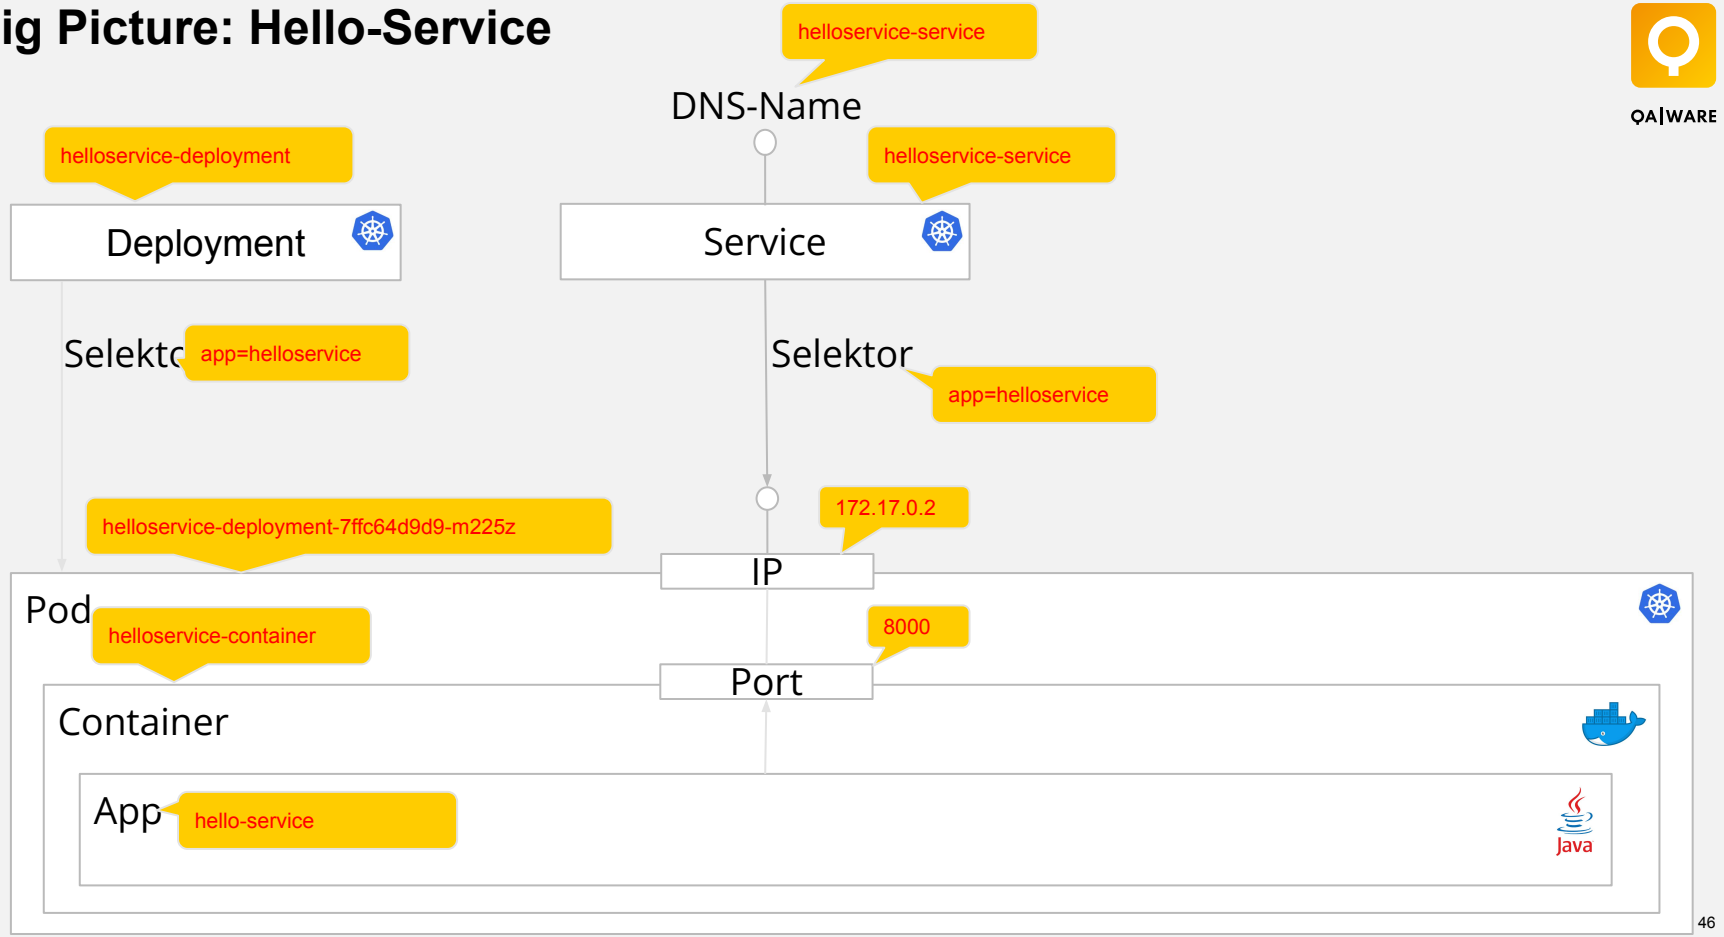

Config Maps

Wichtige Kubernetes-Konzepte

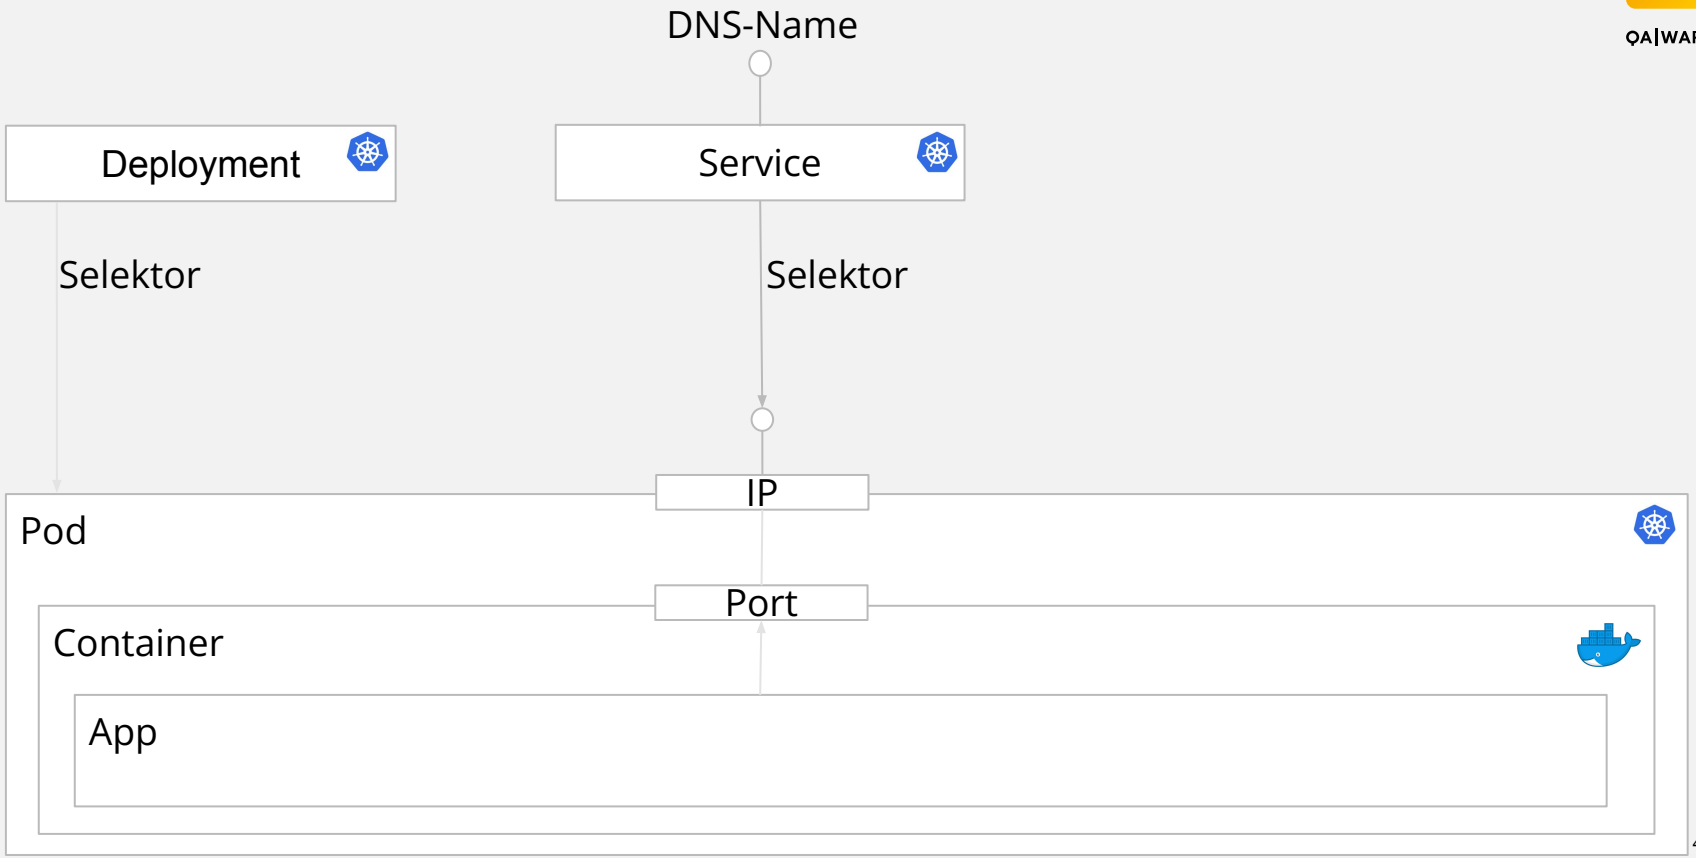

Wichtige Kubernetes-Konzepte

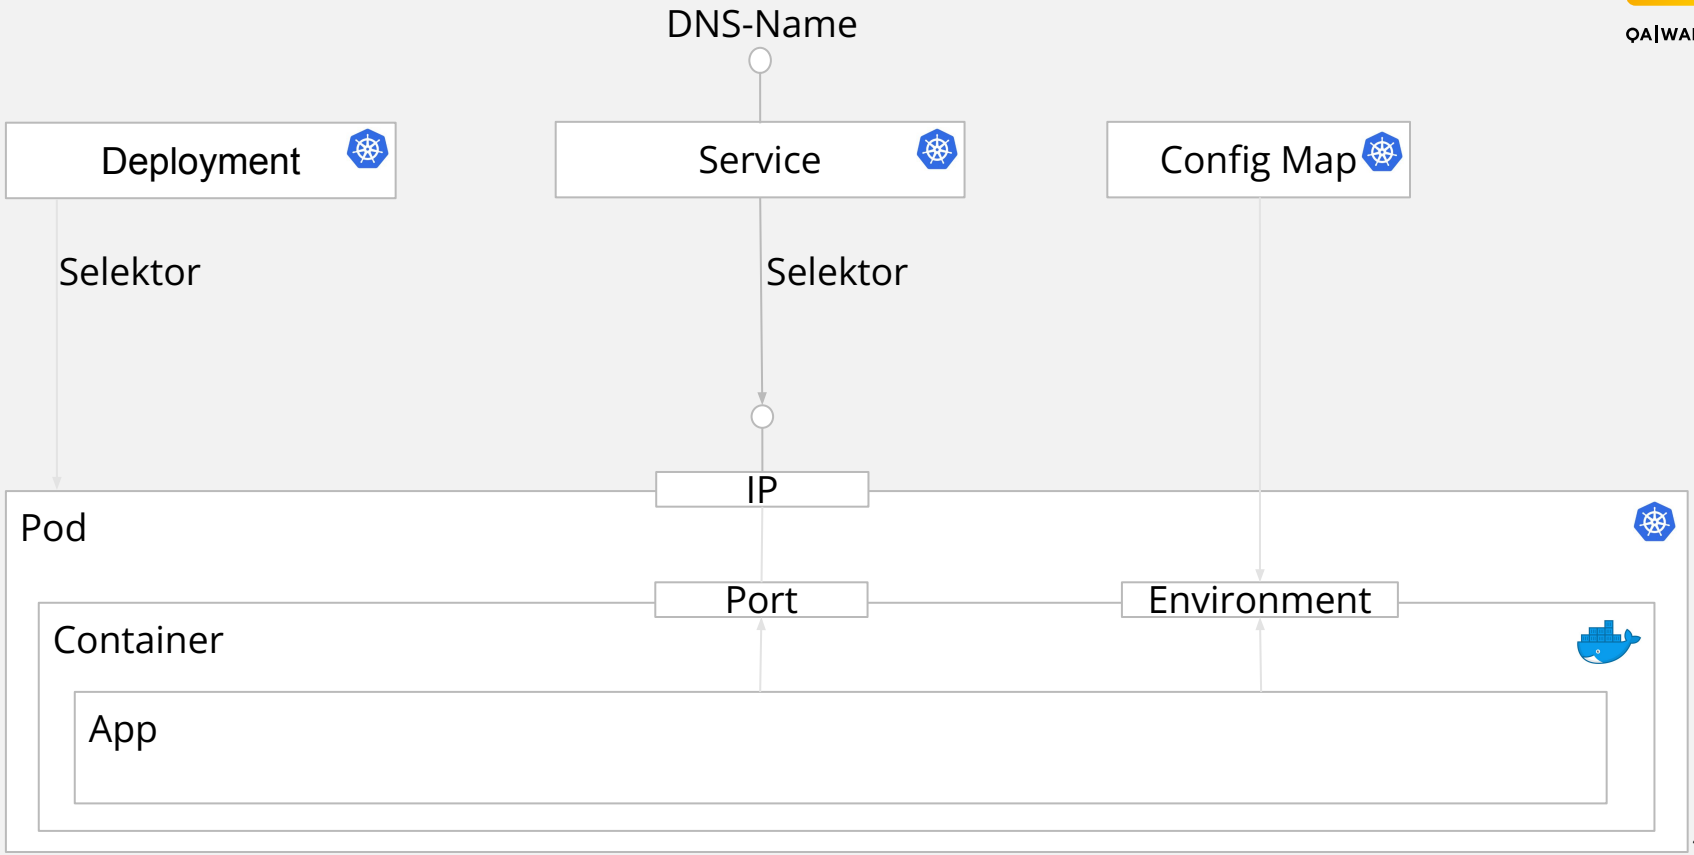

Konfiguration: Config Maps (1)

```yaml
apiVersion: v1
kind: ConfigMap
metadata:
  name: game-demo
data:
  # property-like keys; each key maps to a simple value
  player_initial_lives: "3"
  ui_properties_file_name: "user-interface.properties"
```

Konfiguration: Config Maps (2)

```yaml
apiVersion: v1
kind: Pod
metadata:
  name: configmap-demo-pod
spec:
  containers:
    - name: demo
      image: alpine
      command: ["sleep", "3600"]
      env:
        # Define the environment variable
        - name: PLAYER_INITIAL_LIVES    # Notice that the case is different here
          valueFrom:                    # from the key name in the ConfigMap.
            configMapKeyRef:
              name: game-demo           # The ConfigMap this value comes from.
              key: player_initial_lives # The key to fetch.
        - name: UI_PROPERTIES_FILE_NAME
          valueFrom:
            configMapKeyRef:
              name: game-demo
              key: ui_properties_file_name
```

Konfiguration: Config Maps (2)

```yaml
apiVersion: v1
kind: Pod
metadata:
  name: configmap-demo-pod
spec:
  containers:
    - name: demo
      image: alpine
      command: ["sleep", "3600"]
      # Import all environment variables from ConfigMap.
      # Keys should already be in screaming snake case.
      envFrom:
        - configMapRef:
            name: game-demo
```

Big Picture: Hello-Service

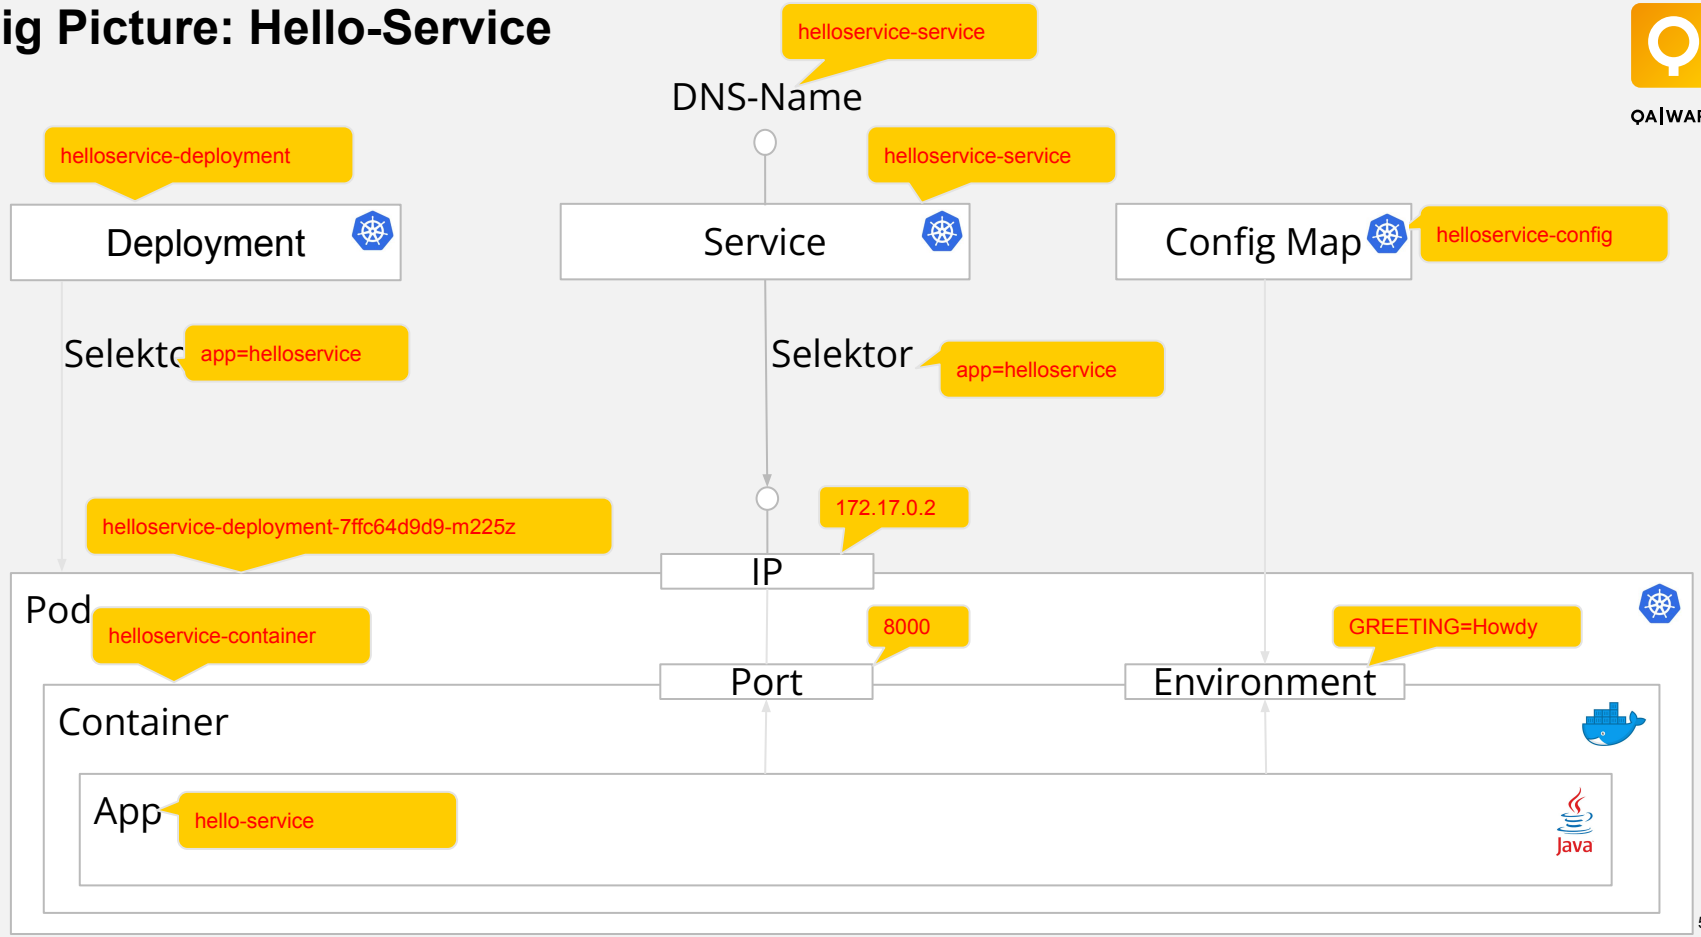

Deklarativer Ansatz mit Kustomize

- Normales Vorgehen:

```
$ kubectl apply -f deployment.yaml
$ kubectl apply -f service.yaml
$ kubectl apply -f configmap.yaml
```

- Für eine Sammlung von vielen Dateien nicht geeignet
- Deshalb: Die yaml-Dateien mit **kustomize** gruppieren!

```
$ kubectl apply -k kustomization.yaml
```

https://kubernetes.io/docs/tasks/manage-kubernetes-objects/kustomization/

Kustomize
Wenn man nicht jede Datei einzeln ins Cluster schieben will


```yaml
commonLabels:
  app: pizza-service

namespace: pizzeria

resources:
  - deployment.yaml
  - service.yaml
  - pod-disruption-budget.yaml

configMapGenerator:
  - name: pizza-config
     behavior: create
     literals:
     - TOPPING="garlic"

patchesStrategicMerge:
  - deployment-patch.yaml
```

Weitere Konzepte von Kubernetes

Anwendungen:

- **StatefulSet**: Wenn eine Anwendung doch einen Zustand braucht
- **Persistent Volumes**: Zugriff auf persistenten Speicher

Global:

- **DaemonSet**: Wenn ein Dienst auf jedem Node im Cluster laufen muss
- **Job**: Wenn eine Aufgabe regelmäßig ausgeführt werden muss

Security:

- **Network Policies**: Wer darf mit wem kommunizieren?

Helm: Verwaltung von Applikationspaketen für Kubernetes.

QA|WARE

HELM https://helm.sh

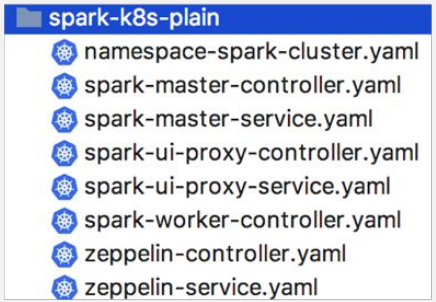

- `kubectl, kubectl, kubectl, ...`
- Konfiguration?
- Endpunkte?

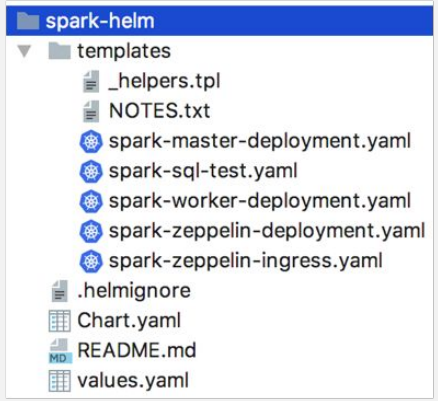

- Chart suchen auf https://hub.kubeapps.com
- Doku dort lesen (README.md)
- Konfigurationsparameter lesen:
  `helm inspect stable/spark`
- Chart starten mit überschriebener Konfiguration:

```
helm install --name my-release
     -f values.yaml stable/spark
```

Helm: Verwaltung von Applikationspaketen für Kubernetes.

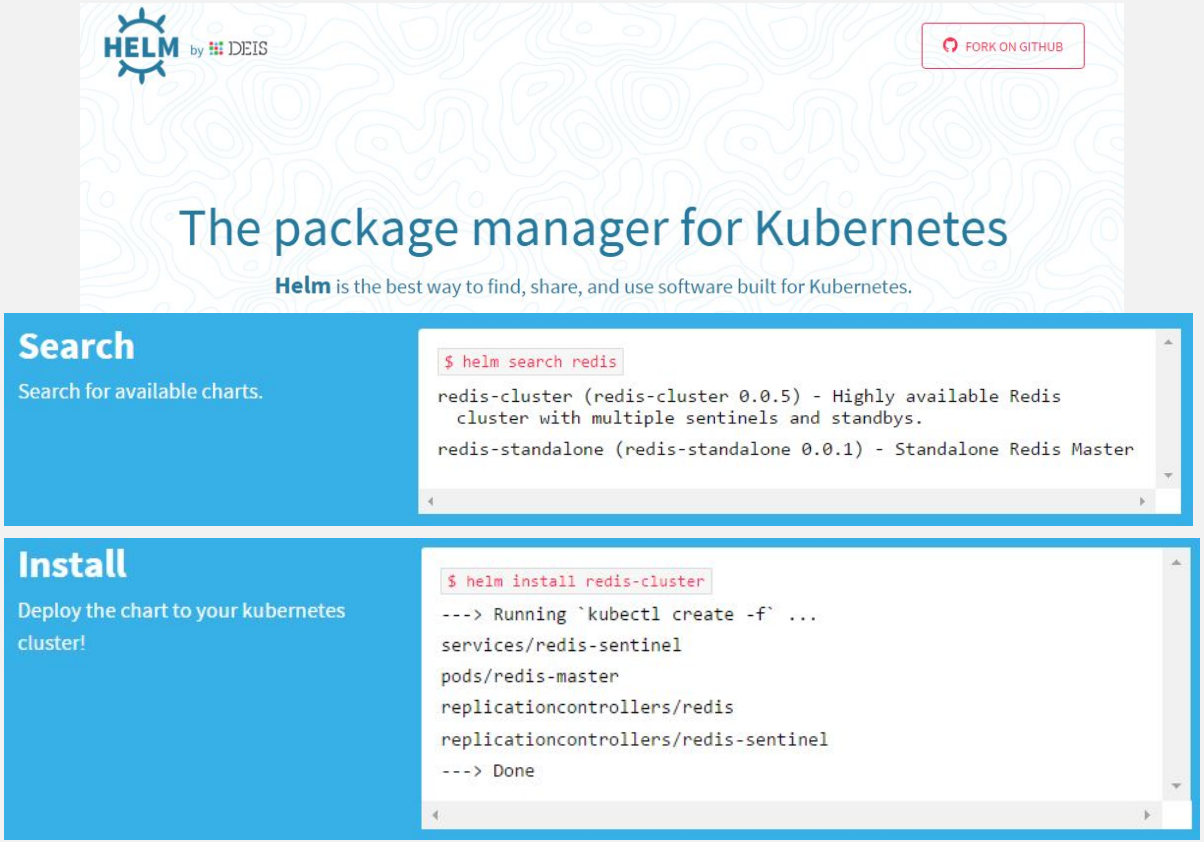

Quelle: https://github.com/helm/helm

Orchestrierungsmuster

Orchestrierungsmuster – Separation of Concerns mit modularen Containern

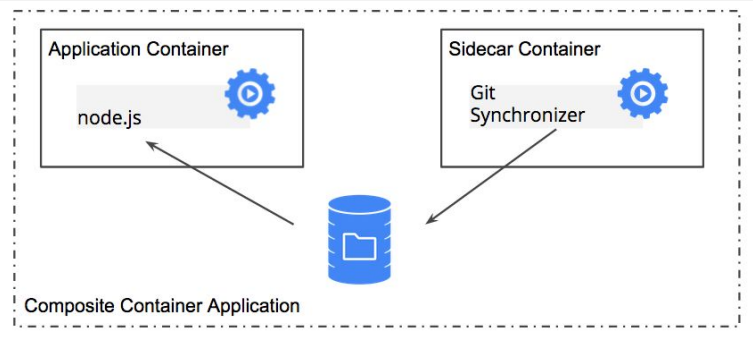

Sidecar Container

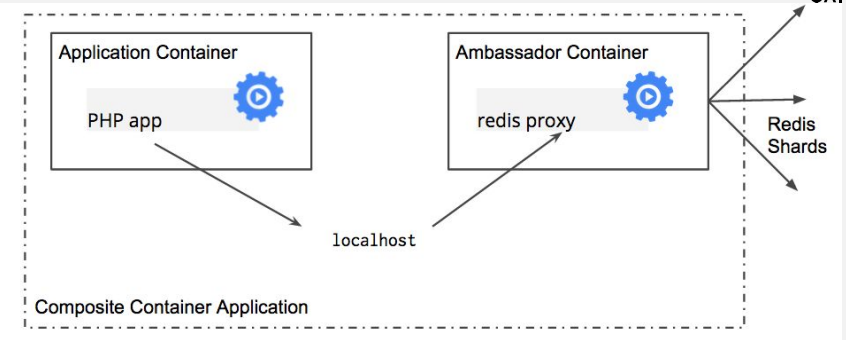

Ambassador Container

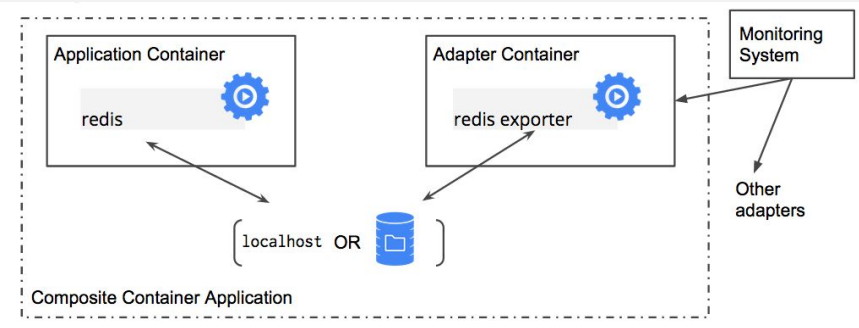

Adapter Container

Quelle: http://blog.kubernetes.io/2015/06/the-distributed-system-toolkit-patterns.html

Sidecar Containers

QA|WARE

Sidecar containers extend and enhance the "main" container, they take existing containers and make them better. As an example, consider a container that runs the Nginx web server. Add a different container that syncs the file system with a git repository, share the file system between the containers and you have built Git push-to-deploy. But you've done it in a modular manner where the git synchronizer can be built by a different team, and can be reused across many different web servers (Apache, Python, Tomcat, etc). **Because of this modularity, you only have to write and test your git synchronizer once and reuse it across numerous apps**. And if someone else writes it, you don't even need to do that.

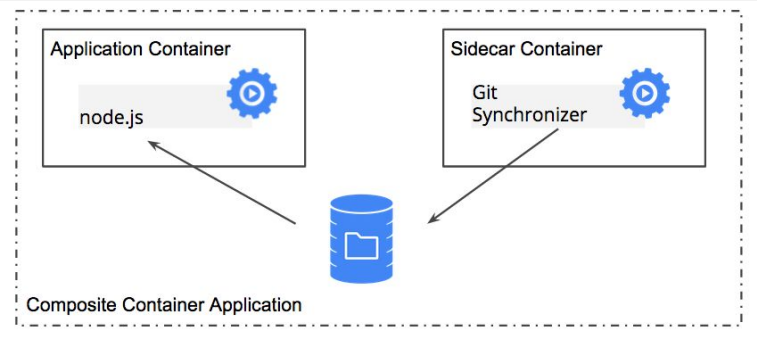

Quelle: https://kubernetes.io/blog/2015/06/the-distributed-system-toolkit-patterns/

Ambassador containers

Ambassador containers proxy a local connection to the world. As an example, consider a Redis cluster with read-replicas and a single write master. You can create a Pod that groups your main application with a Redis ambassador container. **The ambassador is a proxy is responsible for splitting reads and writes and sending them on to the appropriate servers**. Because these two containers share a network namespace, they share an IP address and your application can open a connection on “localhost” and find the proxy without any service discovery. **As far as your main application is concerned, it is simply connecting to a Redis server on localhost**. This is powerful, not just because of separation of concerns and the fact that different teams can easily own the components, but also because in the development environment, you can simply skip the proxy and connect directly to a Redis server that is running on localhost.

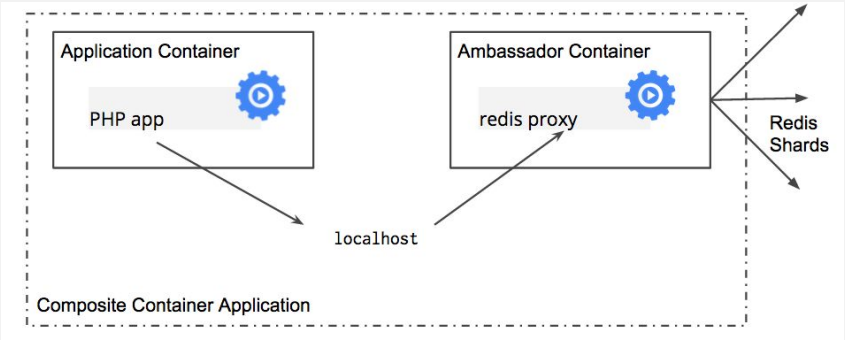

Quelle: https://kubernetes.io/blog/2015/06/the-distributed-system-toolkit-patterns/

Adapter containers

Adapter containers standardize and normalize output. Consider the task of monitoring N different applications. Each application may be built with a different way of exporting monitoring data. (e.g. JMX, StatsD, application specific statistics) but every monitoring system expects a consistent and uniform data model for the monitoring data it collects. **By using the adapter pattern of composite containers, you can transform the heterogeneous monitoring data from different systems into a single unified representation** by creating Pods that groups the application containers with adapters that know how to do the transformation. Again because these Pods share namespaces and file systems, the coordination of these two containers is simple and straightforward.

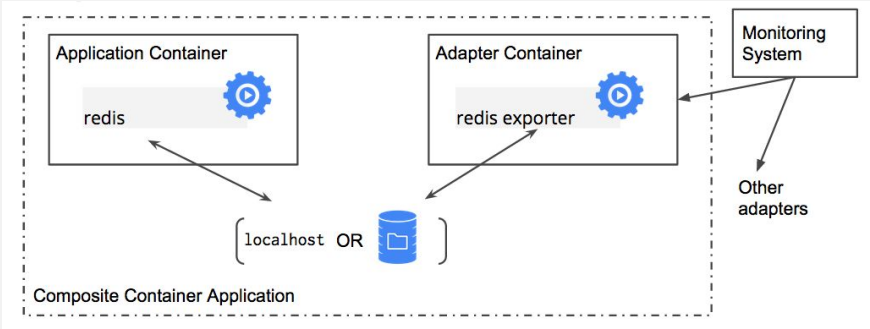

Quelle: https://kubernetes.io/blog/2015/06/the-distributed-system-toolkit-patterns/